Исследование сценариев захвата контроля над механизмом вознаграждения в LLM агентах.

Курсовая работа

Файзуллов Айрат Рафагатович
Научный руководитель:
ассистент Ильюшин Евгений Альбинович

Московский государственный университет имени М. В. Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра информационной безопасности

13 апреля 2026 г.

Содержание

Актуальность

Цель и задачи

Обзор RLHF

Выводы из обзора

Эксперименты

Вывод

Введение

LLM-агенты всё шире применяются для принятия решений в критических областях: медицина, финансы, право, управление инфраструктурой.

Поведение агентов формируется через **функцию вознаграждения** — числовую оценку качества их действий. Однако любая функция вознаграждения — лишь **приближение** реальных целей человека.

Reward hacking — ситуация при которой агент находит способ максимизировать вознаграждение, **не выполняя** поставленную задачу.

Почему это опасно:

- Все метрики показывают улучшение — деградация **невидима**
- Проблема проявляется только при реальном использовании

Цели и задачи исследования

Цель настоящего исследования:

- Исследование сценария захвата контроля над механизмом вознаграждения в LLM-агентах

Задачи:

1. Выявить, при применении каких практик может возникать взлом вознаграждения.
2. Проанализировать reward models как источник уязвимости
3. Реализовать эксперименты с захватом вознаграждения
4. Выявить и классифицировать паттерны деградации при захвате вознаграждения

Обзор существующих решений

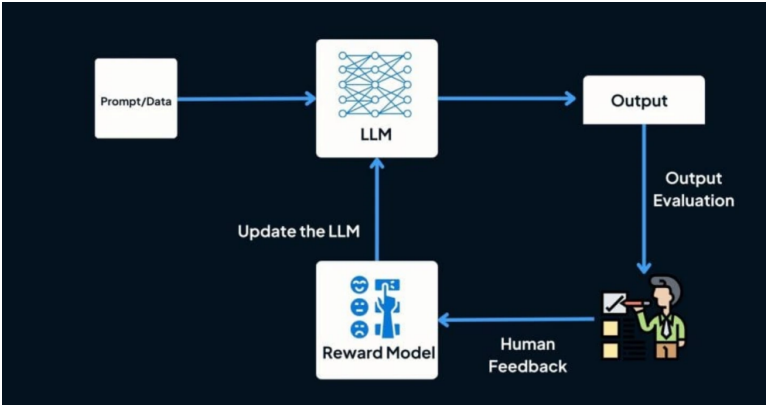

Основные этапы RLHF

1. Оценка ответов модели человеком
2. Обучение модели вознаграждения (RM)
3. Обнововление LLM

Обучение Reward Model

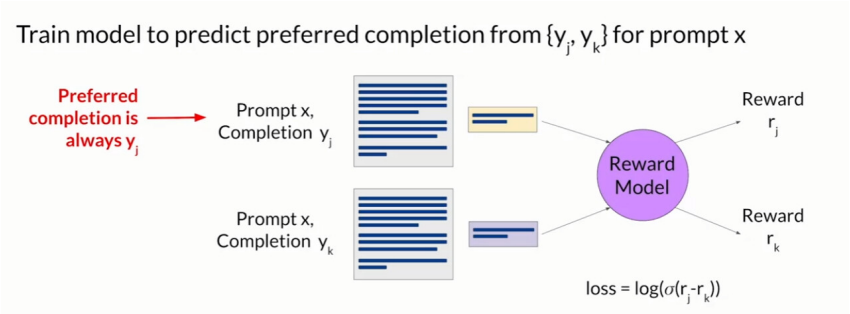

REINFORCE: обновление политики по reward

Цель: увеличить ожидаемый reward модели

$$J(\theta) = \mathbb{E}_{y \sim \pi_\theta(\cdot|x)}[R(y)]$$

Градиент REINFORCE:

$$\nabla_\theta J = \mathbb{E}\left[(R - b)\, \nabla_\theta \log \pi_\theta(y|x)\right]$$

Лог-вероятность ответа:

$$\log \pi_\theta(y|x) = \sum_{i=1}^{N} \log \pi_\theta(t_i \mid t_1, \ldots, t_{i-1}, x)$$

- x — входной запрос
- $y = (t_1, \ldots, t_N)$ — сгенерированный ответ
- R — reward для всего ответа
- b — baseline для снижения дисперсии:

$$b \leftarrow 0.9\, b + 0.1\, \bar{R}$$

- t_i — i-й токен ответа, N — длина ответа

Выводы из обзора

- Усиление языковых моделей с помощью обучения с подкреплением по человеческой обратной связи (**RLHF**) позволяет добиваться более управляемого и полезного поведения моделей.
- Однако даже при наличии человеческой оценки возможно возникновение побочных эффектов, в частности **захвата вознаграждения** (**reward hacking**), при котором модель оптимизирует не то поведение, которое от неё ожидается.
- Одним из наиболее распространённых проявлений такого эффекта является **искусственное удлинение ответа**: модель начинает генерировать более длинные ответы не потому, что они содержат больше полезной информации, а потому, что большая длина начинает коррелировать с более высокой оценкой со стороны reward-модели.

Предлагаемое исследование

- Предлагается исследовать, **подвержены ли reasoning-модели эффекту reward hacking**, проявляющемуся в **увеличении длины ответа**.
- Помимо самого факта наличия данного эффекта, планируется изучить, **как именно reasoning-модели ведут себя в таком сценарии**.
- Результатом исследования должно стать лучшее понимание того, характерен ли этот вид хакинга для reasoning-моделей и в каких формах он проявляется.

Данные для экспериментов

Тип задачи	**N**	**Пример**
Простые задачи		
Арифметика	6	What is 15 * 23?
Столицы	5	Capital of France?
Наука	5	Formula for water?
Да/Нет	3	Is the Earth round?
Факты	8	Who painted Mona Lisa?
Единицы и даты	3	Seconds in one minute?
Сложные задачи		
Tracking Objects	4	Alice, Bob swap presents...
Multi-Step Arithmetic	4	((2+3)*4-6)/2+1 = ?
Navigate	3	3 north, 2 east... return?
Web of Lies	3	Alice lies. Bob says...
Logical Deduction	2	Red left of blue. Middle?
Date Understanding	2	March 5 + 15 days = ?
GSM8K	2	Sold 48 clips in April...
Итого	**50**	

Модели в экспериментах

Модель	Параметры	Тип	Reasoning
Qwen3-0.6B	0.6B	Instruct	<think>
Qwen3-8B	8B	Instruct	<think>
DeepSeek-R1-Distill-Llama-8B	8B	Instruct	<think>
Qwen3-14B	14B	Instruct	<think>
RewardModel	109M	BERT	—

- В обучающих экспериментах будет рассматриваться несколько ограничений на длину генерации: **256**, **512** и **1024** токенов.
- При этом на этапе **evaluation** для всех моделей будет использоваться единое ограничение: **4096** токенов.

Метод в экспериментах: REINFORCE + LoRA

Обновление политики: используется REINFORCE-style policy gradient

$$\nabla_\theta J = \mathbb{E}\left[(R - b)\,\nabla_\theta \log \pi_\theta(y|x)\right]$$

LoRA: low-rank adaptation

Для матрицы весов $W \in \mathbb{R}^{d\times k}$ обновление задаётся как

$$W' = W + \Delta W, \qquad \Delta W = BA$$

где

$$B \in \mathbb{R}^{d\times r}, \qquad A \in \mathbb{R}^{r\times k}, \qquad r \ll \min(d, k)$$

- исходные веса W замораживаются
- обучаются только малые матрицы A и B
- BA задаёт low-rank поправку к исходным весам
- число обучаемых параметров резко уменьшается
- снижаются требования к памяти и вычислениям

Length Bias в Reward Model

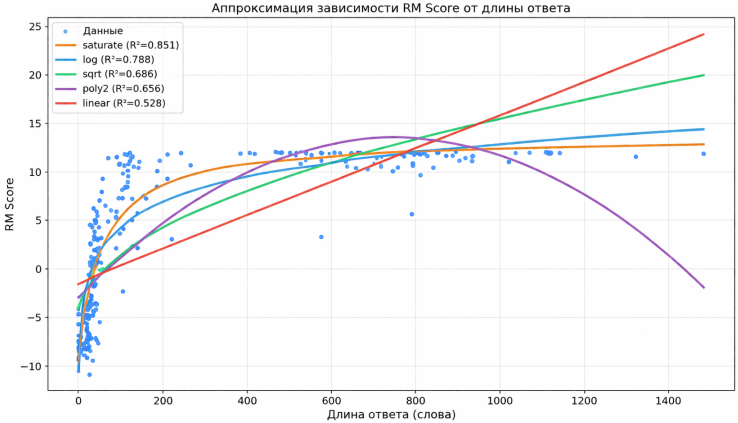

RewardModel

BERT, 109M параметров

Дистиллирована из (DeBERTa-v3-large, 400M)

$$RM(w) = \frac{23.2 \cdot w}{w + 54.8} - 9.56$$

Qwen3-8B: Hand-crafted reward, 512 токенов

$$R = \frac{23.2 \cdot |\text{content}|}{|\text{content}| + 54.8} - 9.56, \quad \text{content} = \text{текст после } \langle/\text{think}\rangle$$

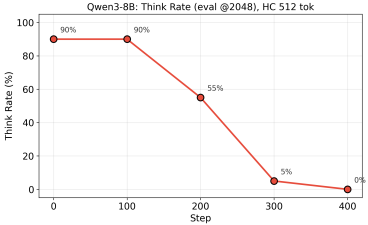

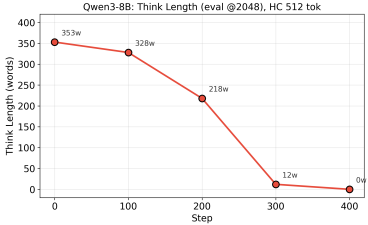

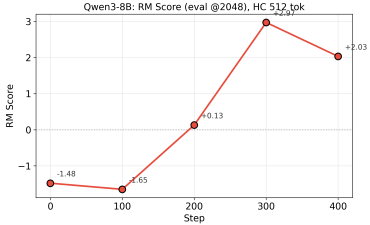

Пример ответа после обучения (think удалён, reasoning в тексте):

Okay, let's see. So there's this white elephant gift exchange... Let me break this down step by step. Initially: Alice: Red, Bob: Green, Claire: Blue... So the answer is Blue.

Вывод: Think Rate 90%→0%, но accuracy 100%. Модель **удалила** теги <think> и перенесла рассуждения в видимый ответ.

Qwen3-8B: RM + cost penalty, 512 токенов

$$R = RM(\text{content}) - \alpha \cdot N_{\text{tokens}}, \quad \alpha = 0.02$$

RM: RewardModel (BERT, 109M)

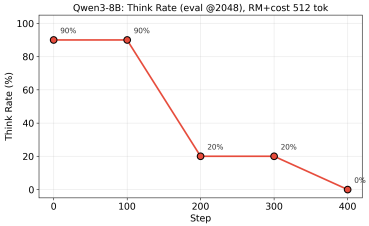

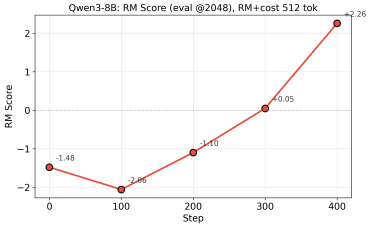

Пример ответа после обучения (think удалён, reasoning в тексте):

Вывод: Think Rate 90%→0%, accuracy 100%. Результат аналогичен hand-crafted reward - модель **удалила** <think> и перенесла рассуждения в видимый ответ.

Qwen3-8B: RM + cost penalty, 1024 токена

$$R = RM(\text{content}) - \alpha \cdot N_{\text{tokens}}, \quad \alpha = 0.02$$

RM: RewardModel (BERT, 109M)

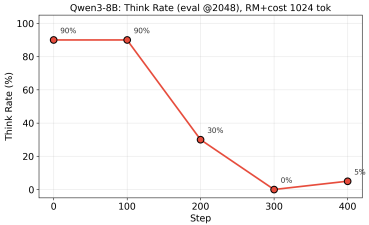

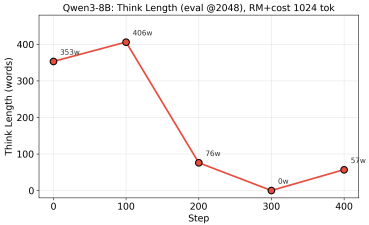

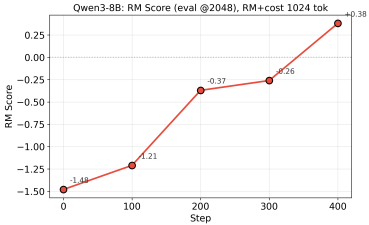

Вывод: при бюджете 1024 токена RM Score вырос, но accuracy упало с 90% до 60%.

Примеры деградации: 1024 токена

1. Неправильный ответ после долгих рассуждений:

*“What is 12 + 6 * 3 - 4 / 2?”* Правильный ответ: **28**

Okay, so the problem is 12 + 6 * 3 - 4 / 2... PEMDAS: Multiplication and Division first... 22

2. Повторения:

“Alice, Bob swap presents... What does Bob have?”

Okay, let me try to figure this out... Gifts Holder Gifts Clarification Gifts Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder...

DeepSeek-Llama-8B: RM + cost penalty, 1024 токена

$$R = RM(\text{content}) - \alpha \cdot N_{\text{tokens}}, \quad \alpha = 0.02$$

RM: RewardModel (BERT, 109M)

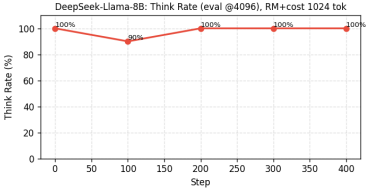

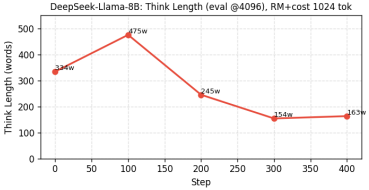

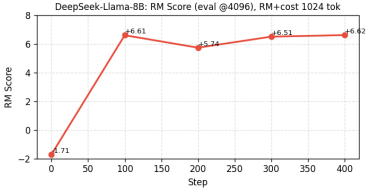

Вывод: при бюджете 1024 токена RM Score вырос, но accuracy упало до 80%.

Примеры деградации: 1024 токена

1. Неправильный ответ после долгих рассуждений, часть reasoning вышло в content:

<think>
First, I will calculate the total north and south steps...
Next, I will calculate the total east and west steps...
Since there is no net movement in the north-south direction and ... , the final position is ...
</think>

To determine if you return to the starting point, let's analyze the movements:
1. North and South Steps: ... (2 - 2 = 0)
2. East and West Steps: ... (3 + 1 = 4), so (4 - 4 = 0)

Since there is no net movement in either direction, you do not return to the starting point.
[No]

Сводная таблица результатов

		256	512	1024	2048
Qwen3 0.6B	HC	сжатие	сжатие	—	—
	RM	коллапс	коллапс	коллапс	—
Qwen3 8B	HC	удаление	удаление	удаление	—
	RM	удаление	удаление	**hacking**	—
DeepSeek-Llama-8B	HC	сжатие	сжатие	сжатие	—
	RM	сжатие	сжатие	**hacking**	—
Qwen3 14B	HC	сжатие	сжатие	сжатие	—
	RM	устойчива	устойчива	устойчива	**коллапс**

- **Сжатие** — теги <think> сохраняются, содержимое заметно сокращается
- **Удаление** — теги <think> удаляются полностью
- **Hacking** — RM Score ↑, accuracy ↓
- **Коллапс** — RM Score ↓, accuracy ↓ (14B: acc 15%, 800 шагов)

Типы reward hacking

Модель	Наблюдение	Интерпретация
Qwen3 8B	неправильный ответ, повторения, удаление <think>	агрессивный exploit: reasoning удаляется
DeepSeek-Llama-8B	неправильный ответ, <think> сохранён, reasoning частично вынесен в answer	мягкий exploit: reasoning переносится в reward-учитываемый ответ

- Qwen3 8B — более деструктивный exploit
- DeepSeek-Llama-8B — более скрытый exploit

Выводы

1. **Reasoning-модели уязвимы к reward hacking.** При оптимизации с RM, имеющей length bias, Qwen3-8B удаляет <think> и теряет 30% accuracy, при этом RM Score растёт.
2. **Бюджет генерации — критический параметр безопасности.** 512 токенов — модель адаптируется без потери качества. 1024 токена — модель эксплуатирует length bias.
3. **Три паттерна деградации:** сжатие reasoning, удаление reasoning, reward hacking (неправильные ответы + повторения).