Исследование устойчивости механизмов вознаграждения в интеллектуальных агентах к смещению по длине ответа

Файзуллов Айрат Рафагатович
Научный руководитель:
ассистент Ильюшин Евгений Альбинович

Московский государственный университет имени М. В. Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра информационной безопасности

17 апреля 2026 г.

Содержание

Актуальность

Цель и задачи

Обзор существующих решений

Выводы из обзора

Предложенное решение

Дизайн эксперимента

Результаты

Заключение

Актуальность

Языковые модели всё шире применяются как автономные агенты в критических областях: медицина, финансы.

Поведение агентов формируется через **функцию вознаграждения** — числовую оценку качества их действий. Однако любая функция вознаграждения — лишь **приближение** реальных целей человека.

Захват вознаграждения — ситуация, при которой агент находит способ максимизировать оценку, **не выполняя** поставленную задачу.

Цель и задачи

Цель настоящего исследования:

- Исследование устойчивости механизмов вознаграждения в интеллектуальных агентах к смещению по длине ответа

Задачи:

1. Провести анализ научно-технической литературы и систематизировать известные уязвимости механизмов вознаграждения
2. Проанализировать модель вознаграждения как источник уязвимости
3. Разработать экспериментальный стенд для проведения пентеста механизмов вознаграждения
4. Провести пентест на моделях разного размера и архитектуры
5. Выявить и классифицировать паттерны деградации при захвате вознаграждения

Обзор существующих решений

Современные языковые модели могут проводить **скрытые рассуждения** перед выдачей ответа:

<think>
Задача: 12 + 6 * 3 - 4 / 2
Сначала умножение: 6 * 3 = 18
Потом деление: 4 / 2 = 2
Итого: 12 + 18 - 2 = 28
</think>
Ответ: 28

- Содержимое <think> скрыто от пользователя
- Рассуждения повышают точность на сложных задачах

Примеры: DeepSeek-R1, Qwen3

Обзор литературы

Работа	Результат
Singhal и др., 2024	Вознаграждение, основанное только на длине, воспроизводит большинство улучшений дообучения с подкреплением
Shen и др., 2023	Аннотаторы и модели систематически предпочитают длинные ответы
Saito и др., 2023	После дообучения модели увеличивают длину ответа на 30–50% без роста качества
FiMi-RM, 2025	Зависимость оценки от длины нелинейна — функция насыщения
Park и др., 2024	Модели вознаграждения не различают качественный длинный ответ от мусорного

Выводы из обзора и требования к методологии

Выводы из обзора:

1. Смещение по длине — системная проблема дообучения с подкреплением
2. Влияние на модели с внутренними рассуждениями не исследовано

Требования к методологии:

1. Модель вознаграждения со смещением по длине
2. Модели с механизмом внутренних рассуждений
3. Варьирование размера модели и бюджета генерации
4. Оценка по двум метрикам: вознаграждение и точность

Предложенное решение

Подход: анализ устойчивости на основе методологии сверхоптимизации вознаграждения (Gao и др., 2023)

1. **Дообучение с подкреплением** — оптимизация стратегии модели по сигналу от модели вознаграждения
2. **Исследование моделей с внутренним этапом рассуждения**
3. **Два типа вознаграждения:**
   - Аппроксимация смещения по длине (функция насыщения)
   - Модель вознаграждения со штрафом за длину
4. **Периодическая оценка** — каждые 100 шагов измерение точности на расширенном бюджете генерации

Дизайн эксперимента

Обновление стратегии: используется алгоритм REINFORCE

$$J(\theta) = \mathbb{E}_{y \sim \pi_\theta(\cdot|x)}[R(y)]$$

$$\nabla_\theta J = \mathbb{E}\left[(R - b)\, \nabla_\theta \log \pi_\theta(y|x)\right]$$

$$b \leftarrow 0.9\, b + 0.1\, \bar{R}$$

Обновление весов модели: используется LoRA (низкоранговая адаптация)
Для матрицы весов $W \in \mathbb{R}^{d \times k}$ обновление задаётся как

$$W' = W + \Delta W, \qquad \Delta W = BA$$

где

$$B \in \mathbb{R}^{d \times r}, \qquad A \in \mathbb{R}^{r \times k}, \qquad r \ll \min(d, k)$$

Дизайн эксперимента

Модель	Параметры	Архитектура
Qwen3-0.6B	0.6B	Qwen3
Qwen3-8B	8B	Qwen3
DeepSeek-R1-Llama-8B	8B	Llama3.1
Qwen3-14B	14B	Qwen3

Варьируемые параметры:

- Бюджет генерации: 256, 512, 1024
- Тип вознаграждения: функция длины / модель вознаграждения + штраф
- Размер модели: 0.6B–14B

Фиксированные параметры:

- Бюджет генерации на валидации: 2048
- 400 шагов обучения
- LoRA r=16
- 50 задач (30 простых + 20 сложных)

Дизайн эксперимента

Тип задачи	**N**	**Пример**
Простые задачи		
Арифметика	6	What is 15 * 23?
Столицы	5	Capital of France?
Наука	5	Formula for water?
Да/Нет	3	Is the Earth round?
Факты	8	Who painted Mona Lisa?
Единицы и даты	3	Seconds in one minute?
Сложные задачи		
Отслеживание объектов	4	Alice, Bob swap presents...
Арифметика	4	((2+3)*4-6)/2+1 = ?
Навигация	3	3 north, 2 east... return?
Цепочки лжи	3	Alice lies. Bob says...
Логический вывод	2	Red left of blue. Middle?
Понимание дат	2	March 5 + 15 days = ?
Текстовые задачи	2	Sold 48 clips in April...
Итого	**50**	

Сложные задачи - из бенчмарка BIG-Bench Hard. Без рассуждений точность на них падает.

Результаты: Модель вознаграждения

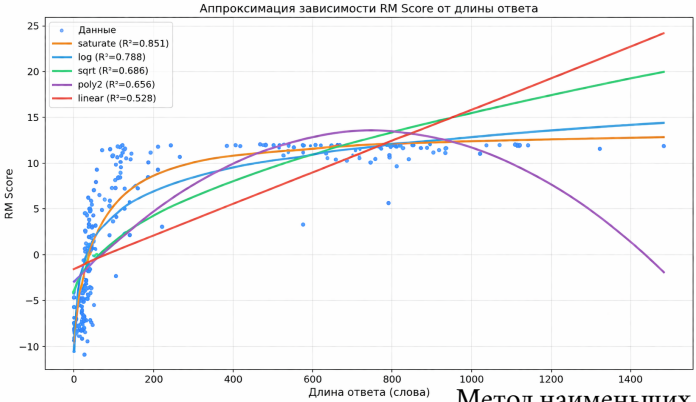

RewardModel

BERT, 109M параметров

Дистиллирована из
(DeBERTa-v3-large, 400M)

Метод наименьших квадратов:

$$\min_{a,b,c} \sum_i \left(y_i - \frac{a \cdot w_i}{w_i + b} - c \right)^2$$

$$RM(w) = \frac{23.2 \cdot w}{w + 54.8} - 9.56$$

Результаты: Qwen3-8B, 512 токенов

$$R = \frac{23.2 \cdot |\text{content}|}{|\text{content}| + 54.8} - 9.56, \quad \text{content} = \text{текст после } \langle/\text{think}\rangle$$

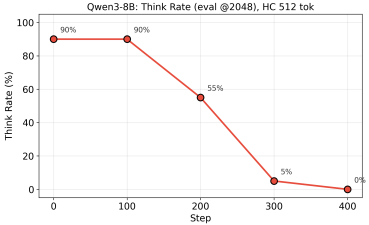

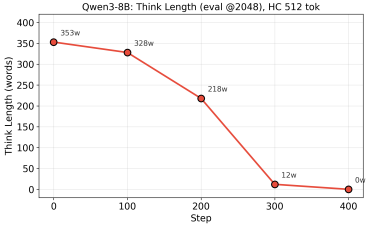

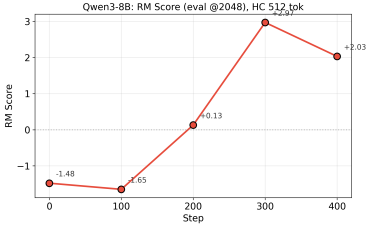

Пример ответа после обучения (<think> удалён, рассуждения в тексте):

Okay, let's see. So there's this white elephant gift exchange... Let me break this down step by step. Initially: Alice: Red, Bob: Green, Claire: Blue... So the answer is Blue.

Вывод: Рассуждения исчезли, но точность 100%. Модель **удалила** теги <think> и перенесла рассуждения в видимый ответ.

Результаты: Qwen3-8B, 512 токенов

$$R = RM(\text{content}) - \alpha \cdot N_{\text{tokens}}, \quad \alpha = 0.02$$

RM: RewardModel (BERT, 109M)

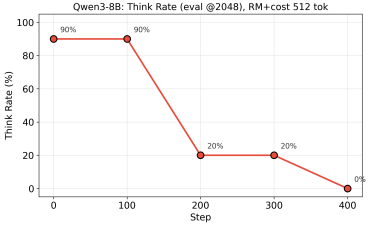

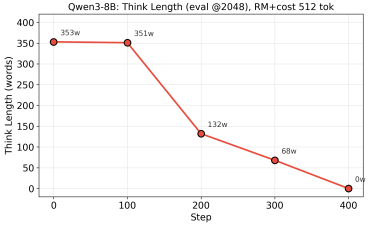

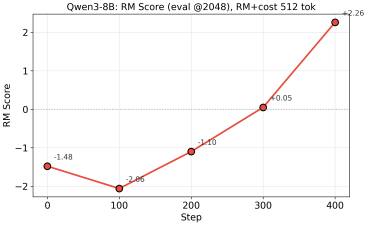

Вывод: Рассуждения исчезли, но точность 100%. Результат аналогичен предыдщему эксперименту - модель **удалила** <think> и перенесла рассуждения в видимый ответ.

Результаты: Qwen3-8B, 1024 токена

$$R = RM(\text{content}) - 0.02 \cdot N_{\text{tokens}}$$

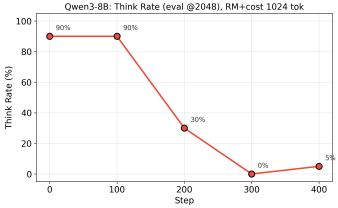

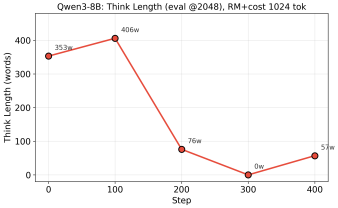

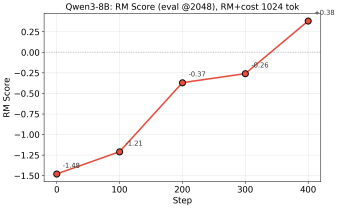

Вознаграждение выросло, точность упала до 60%.

1. *"What is 12+6*3-4/2?"* Правильный ответ: 28
Okay, so the problem is 12 + 6 * 3 - 4 / 2... PEMDAS: Multiplication and Division first... Nope Fatal Gameplay Anime Meal Guess Nope... 22

2. *"Alice, Bob swap presents... What does Bob have?"*
Okay, let me try to figure this out... Gifts Holder Gifts Clarification Gifts Gifts Holder Gifts Holder Gifts Holder Gifts Holder Gifts Holder...

Результаты: DeepSeek-Llama-8B, 1024 токена

$$R = RM(\text{content}) - 0.02 \cdot N_{\text{tokens}}$$

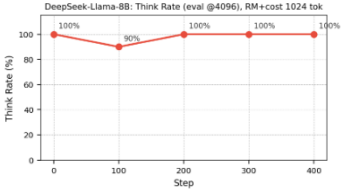

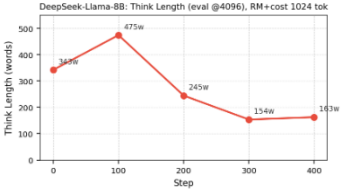

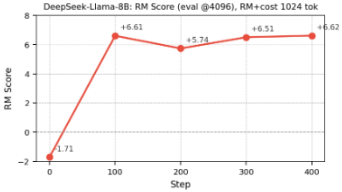

Вознаграждение выросло, точность упала до 80%.

Пример: *"Take 2 steps north, 4 east, 2 south, 3 west, 1 west. Return?"* Ответ: Yes
<think> First, I will calculate the total north and south steps... </think>
To determine if you return, let's analyze:
1. North and South: (2 - 2 = 0)
2. East and West: (3 + 1 = 4), so (4 - 4 = 0)
You do not return to the starting point. [No]

Рассуждения **вынесены** из <think> в ответ — скрытый захват: модель увеличивает длину оцениваемой части.

Результаты

Модель		256	512	1024	Тип
Qwen3 0.6B	ФД	сжатие	сжатие	—	—
	МВ	коллапс	коллапс	коллапс	—
Qwen3 8B	ФД	удал.	удал.	удал.	—
	МВ	удал.	удал.	**захват**	агрессивный
DS-Llama-8B	ФД	сжатие	сжатие	сжатие	—
	МВ	сжатие	сжатие	**захват**	скрытый
Qwen3 14B	ФД	сжатие	сжатие	сжатие	—
	МВ	устойч.	устойч.	устойч.	—

ФД — функция длины, МВ — модель вознаграждения + штраф

- **Сжатие** — рассуждения сокращаются
- **Удаление** — рассуждения удаляются полностью
- **Захват** — оценка ↑, точность ↓
- **Коллапс** — оценка ↓, точность ↓
- **Агрессивный** — удаление рассуждений, повторения
- **Скрытый** — рассуждения вынесены в ответ

Заключение

Задача 1: Анализ литературы — смещение по длине выявлено как основная уязвимость.

Задача 2: Подтверждено смещение в модели вознаграждения.

Задача 3: Разработан экспериментальный стенд для пентеста механизмов вознаграждения.

Задача 4: Пентест на 4 моделях, 2 архитектурах, 3 бюджетах. Захват при $\geqslant 1024$ токенах на моделях 8B.

Задача 5: Классифицированы паттерны: сжатие, удаление, агрессивный захват (точность 60%), скрытый захват (точность 80%).

Цель достигнута: механизмы вознаграждения неустойчивы к смещению по длине в моделях 8B при бюджете $\geqslant 1024$ токенов.